Mapování sémantické konvergence a lexikální diverzity v předvolebních debatách 2025*

Michal Tobiáš Dobeš

Katedra obecné lingvistiky, Univerzita Palackého v Olomouci

Předmět: **KRAD** — Kritická analýza diskurzu

Březen 2026

Abstrakt

Předkládaná studie navrhuje a aplikuje kvantitativní pipeline pro analýzu politického diskurzu na korpusu 7 715 promluv z předvolebních debat České televize (podzim 2025). Metodologický rámec integruje sentence embeddingy (model `paraphrase-multilingual-MiniLM-L12-v2`), redukci dimenzí algoritmem UMAP, lexikální metriky (Type-Token Ratio, Maas index) a volitelné obohacení promluv pomocí velkého jazykového modelu (sentiment, agresivita, rétorickéé rámce). Výsledky vizualizované prostřednictvím sémantické mapy, bubble chartu rétorického profilu a heatmapy tematické dominance ukazují výraznou konvergenci středových stran v sémantickém prostoru, odlišnou syntaktickou komplexitu Pirátů a specifické tematické strategie protisystémových subjektů. Navržená metoda demonstruje potenciál komputačních přístupů pro obecnou lingvistiku a kritickou analýzu diskurzu.

Klíčová slova: politický diskurz, sentence embeddings, UMAP, lexikální diverzita, Maas index, kvantitativní lingvistika, NLP, předvolební debaty

*Zdrojový kód a data: https://github.com/Dobes-Michal-Tobias/Semantic-debate-mapping

Obsah

1 Úvod **3**

2 Data **3**

3 Metodologie **4**

3.1 Fáze 1: Parsování přepisu 4

3.2 Fáze 2: Lexikální metriky 4

3.3 Fáze 3: Sentence embeddingy 5

3.4 Fáze 4: Redukce dimenzí 5

3.5 Fáze 5: LLM anotace (volitelná) 6

3.6 Fáze 6: Vizualizace 6

4 Výsledky **6**

4.1 Sémantická mapa politického diskurzu 6

4.2 Rétorický profil: Lexikální diverzita a syntaktická komplexita 8

4.3 Heatmapa tematické dominance 9

5 Diskuse **10**

5.1 Sémantická konvergence a diskurzivní mainstream 11

5.2 Lexikální profily jako indikátory rétorického stylu 11

5.3 Tematické strategie a formátové efekty 11

5.4 Limity studie 11

6 Závěr **12**

Dostupnost dat a kódu **12**

Literatura **13**

1 Úvod

Předvolební kampaň před parlamentními volbami v říjnu 2025 představovala v českém politickém prostředí událost s vysokou diskurzivní dynamikou. Televizní debaty České televize, vysílané od září do října 2025, poskytly systematický a veřejně přístupný zdroj politických promluv pokrývající široké spektrum témat — od ekonomiky přes vzdělávání po zahraniční politiku. Tento materiál tak vytváří vhodný korpus pro kvantitativní analýzu politického diskurzu.

Kritická analýza diskurzu (CDA), jak ji rozpracovali Fairclough (1995) a van Dijk (2001), byla tradičně kvalitativní disciplínou, založenou na interpretativní práci výzkumníka s textem. S rozvojem metod zpracování přirozeného jazyka (NLP) a zejména s příchodem kontextuálních jazykových modelů se však otevírá prostor pro komplementární kvantitativní přístupy, které umožňují zpracovat rozsáhlé korpusy a identifikovat vzorce nepozorovatelné manuální analýzou.

Předkládaná studie si klade za cíl navrhnout a aplikovat reprodukovatelnou analytickou pipeline — nazvanou **Political Discourse Topology (PDT)** — která transformuje surové textové přepisy debat na strukturované sémantické, lexikální a rétorické reprezentace. Konkrétně jsou formulovány tři výzkumné otázky:

1. Jak se liší sémantický prostor projevů jednotlivých politických stran, měřeno prostřednictvím shluků ve dvourozměrné UMAP projekci sentence embeddingů?

2. Jaká je lexikální rozmanitost a syntaktická komplexita vyjadřování napříč stranami, kvantifikovaná pomocí TTR a Maas indexu?

3. Jaké tematické a rétorické strategie strany využívají v kontextu ekonomické debaty?

2 Data

Analyzovaný korpus tvoří přepisy debat České televize z předvolebního období (září–říjen 2025). Základní parametry datového souboru shrnuje tabulka 1.

Tabulka 1: Přehled analyzovaného korpusu

Parametr	**Hodnota**
Počet promluv (speech acts)	7 715
Počet politických subjektů	8 stran + moderátor
Počet unikátních mluvčích	115
Počet tematických bloků	18
Kódování zdrojového souboru	UTF-8

V korpusu je zastoupeno osm politických subjektů: ANO, SPOLU, Piráti, STAN, SPD, Stačilo!, Motoristé sobě a Přísaha. Tematické bloky pokrývají oblast ekonomiky, dopravy, zdravotnictví, průmyslu, vzdělávání, vztahů s EU, justice, životního prostředí, společenských výzev, digitalizace, zahraniční politiky, bezpečnosti a obrany, jakož i několik přímých duelů mezi kandidáty. Promluvy moderátorů (celkem 3 155) jsou v analýze zachovány jako referenční kategorie, neboť jejich diskurzivní profil (krátké, lexikálně diverzní výroky) poskytuje užitečný kontrast.

Tabulka 2: Počet promluv a celkový rozsah projevů dle politického subjektu

Strana / Role	**Počet promluv**	**Celkem slov**	**Počet mluvčích**
moderátor	3 155	70 541	14
SPOLU	840	39 055	13
ANO	721	38 639	12
SPD	579	29 300	13
Motoristé	546	27 466	12
Stačilo!	534	26 782	13
Přísaha	491	24 773	12
STAN	448	24 875	13
Piráti	401	27 308	13

3 Metodologie

Analytická pipeline PDT sestává ze šesti fází, z nichž pátá (LLM obohacení) je volitelná. Každá fáze implementuje princip idempotence — kontroluje existenci výstupního souboru a shodu počtu řádků, čímž je zajištěna reprodukovatelnost i efektivita opakovaných běhů.

3.1 Fáze 1: Parsování přepisu

Surový textový přepis je transformován na strukturovaný tabulkový formát (CSV) pomocí regulárního výrazu, který rozpoznává hlavičku promluvy ve formátu:

```
Jméno Příjmení (Strana) [HH:MM:SS](Téma): Text promluvy
```

Pokračovací řádky (bez hlavičky) jsou připojeny k předchozí promluvě. Pro každou promluvu jsou vypočteny odvozené atributy: časová značka v sekundách, počet slov, počet vět (detekce koncových interpunkčních znaků) a průměrná délka věty ve slovech.

3.2 Fáze 2: Lexikální metriky

Pro kvantifikaci lexikální diverzity jsou použity dvě komplementární míry:

Type-Token Ratio (TTR). Poměr počtu unikátních slovních typů V k celkovému počtu tokenů N:

$$\mathrm{TTR} = \frac{|V|}{|N|} \tag{1}$$

Hodnota blízká 1,0 indikuje vysokou lexikální variabilitu; hodnota blízká 0 naopak signalizuje vysokou míru opakování.

Maas index (Maas, 1972). Logaritmická transformace, která tlumí závislost na délce textu:

$$a^2 = \frac{\log N - \log V}{(\log N)^2} \tag{2}$$

Nižší hodnota a^2 indikuje vyšší lexikální bohatství. Tato míra je vhodnější pro komparativní analýzu promluv různých délek než prostý TTR.

Tokenizace je záměrně implementována jazykově agnostickým způsobem (převod na malá písmena, segmentace na mezerách), čímž je zajištěna transparentnost a nezávislost na externích morfologických nástrojích.

3.3 Fáze 3: Sentence embeddingy

Každá promluva je zakódována do hustého vektorového prostoru pomocí modelu `paraphrase-multilingual-MiniLM-L12-v2` z knihovny Sentence Transformers (Reimers a Gurevych, 2019). Jedná se o dvanáctivrstvý multilinguální model založený na architektuře MiniLM, trénovaný na parafrázových párech ve více než 50 jazycích včetně češtiny. Výstupní dimenze embeddingu je 384.

Model produkuje pro každou promluvu vektor $\mathbf{e}_i \in \mathbb{R}^{384}$, kde sémanticky podobné promluvy mají vysokou kosinovou podobnost. Celkem bylo zakódováno 7 715 promluv s velikostí dávky 64.

3.4 Fáze 4: Redukce dimenzí

Pro vizualizaci 384-dimenzionálního embeddingového prostoru ve dvou dimenzích byl použit algoritmus UMAP (Uniform Manifold Approximation and Projection; McInnes et al., 2018). UMAP zachovává jak lokální, tak globální topologickou strukturu dat, čímž poskytuje věrohodnější vizuální reprezentaci sémantických shluků než lineární metoda PCA. Parametry redukce: `n_components=2`, `random_state=42`.

Jako záložní metoda je implementována PCA ze knihovny scikit-learn, která se automaticky aktivuje v prostředí bez nainstalovaného balíčku `umap-learn`.

Pro každou politickou stranu je dále vypočten **centroid** — průměrný embeddingový vektor všech promluv dané strany v plném 384D prostoru. Mezistraná kosinová vzdálenost centroidů slouží jako míra celkové sémantické odlišnosti rétorických pozic.

3.5 Fáze 5: LLM anotace (volitelná)

Promluvy mohou být volitelně obohaceny o automaticky generované anotace pomocí modelu Claude (Anthropic API). Pro každou promluvu jsou generovány tři tagy: *sentiment* (plovoucí hodnota na škále −1,0 až 1,0), *agresivita* (celočíselná škála 0–5) a *dominantní rétorický rámec* (kategoriální proměnná: Economic threat, National sovereignty, Social justice, Fiscal responsibility, EU scepticism, Party attack, Neutral/factual).

Zpracování probíhá v dávkách po 20 promluvách s automatickým checkpointingem po každé dávce, čímž je umožněno přerušení a obnovení procesu.

3.6 Fáze 6: Vizualizace

Na základě vypočtených metrik a embeddingů jsou generovány tři vizualizace: sémantická mapa (scatter plot UMAP projekce), bubble chart rétorického profilu a heatmapa tematické dominance. Technické parametry vizualizací jsou popsány v sekci 4.

4 Výsledky

4.1 Sémantická mapa politického diskurzu

Obrázek 1 zobrazuje dvourozměrnou UMAP projekci sentence embeddingů všech 7 715 promluv. Každý bod představuje jednu promluvu, barva kóduje stranickou příslušnost; hvězdičky označují 2D centroidy stran.

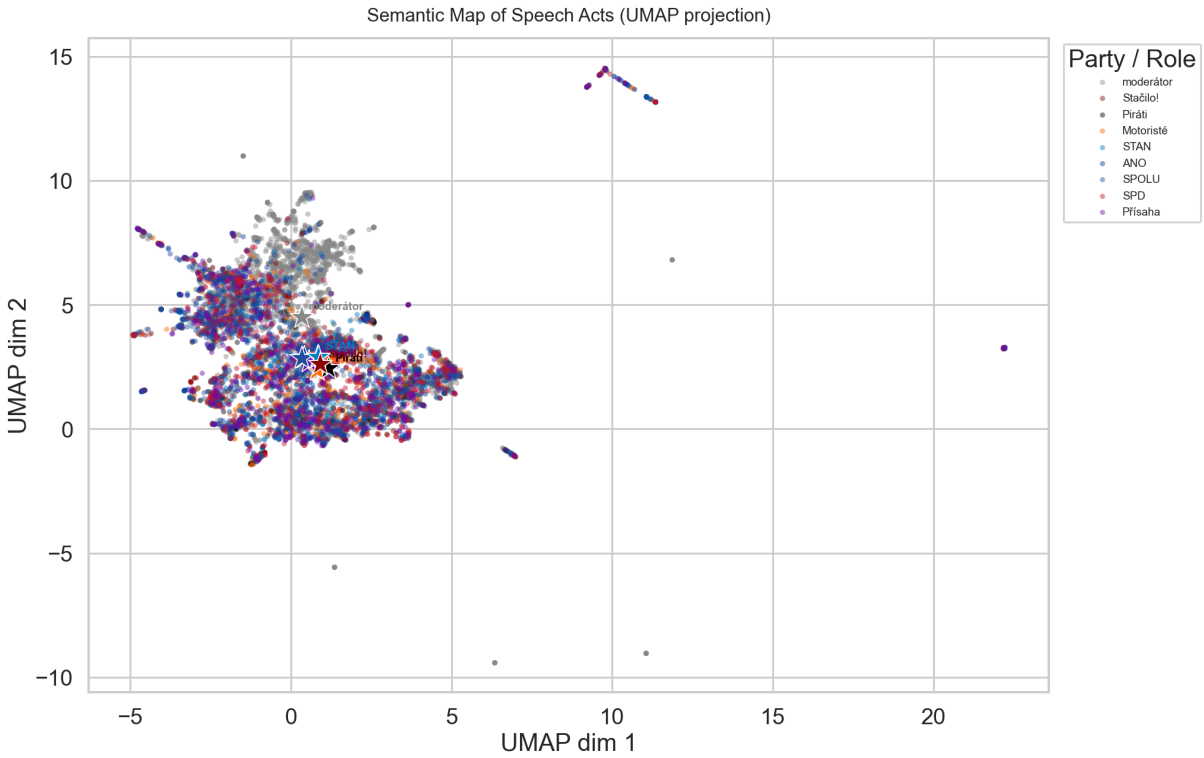

Obrázek 1: Sémantická mapa promluv (UMAP projekce). Každý bod odpovídá jedné promluvě, barva indikuje stranickou příslušnost. Hvězdičky označují centroidy stran v 2D prostoru.

Z vizualizace lze identifikovat několik klíčových vzorců:

1. **Centrální sémantický shluk.** Většina promluv všech parlamentních stran se koncentruje v jednom dominantním shluku v levé části projekce (přibližně $\dim_0 \in [-5, 5]$, $\dim_1 \in [0, 8]$). Tato konvergence naznačuje, že politický diskurz v ekonomickém tématu sdílí značnou část sémantického prostoru napříč ideologickým spektrem.

2. **Centroidy stran.** Centroidy středových a systémových stran (ANO, SPOLU, STAN, Piráti) se nacházejí v těsné blízkosti centra hlavního shluku, zatímco centroidy některých menších subjektů vykazují mírný posun. Moderátor se nachází rovněž v blízkosti centrálního shluku, což odpovídá jeho tematicky neutrální, organizační roli.

3. **Okrajové shluky.** V pravé a horní části projekce lze pozorovat separované menší shluky ($\dim_0 > 10$), které představují sémanticky odlišné typy promluv — pravděpodobně procedurální výroky, emotivní prohlášení nebo specifické duelové formáty. Tyto okrajové body jsou zastoupeny napříč stranami.

4.2 Rétorický profil: Lexikální diverzita a syntaktická komplexita

Obrázek 2 zobrazuje bubble chart, kde osa x reprezentuje průměrnou lexikální diverzitu (TTR), osa y průměrnou délku věty ve slovech a velikost bubliny odpovídá míře agresivity (pokud jsou dostupné LLM tagy).

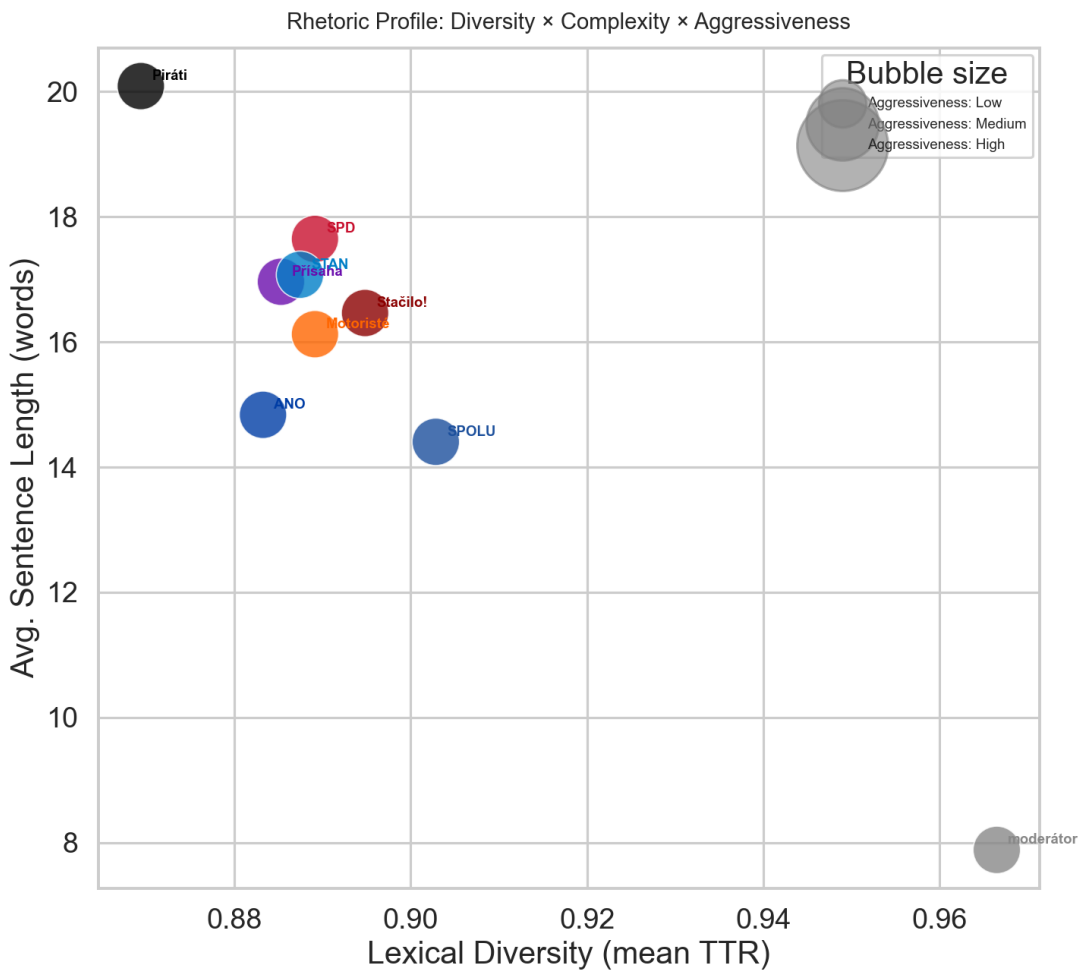

Obrázek 2: Rétorický profil stran: lexikální diverzita (TTR) na ose x, průměrná délka věty na ose y. Velikost bubliny odpovídá míře agresivity.

Kvantitativní hodnoty lexikálních metrik shrnuje tabulka 3.

Tabulka 3: Lexikální metriky dle politického subjektu (seřazeno dle TTR)

Strana / Role	$\overline{\text{TTR}}$	$\overline{a^2}$ **(Maas)**	$\overline{\ell}$ **(slov/věta)**	**Celkem slov**
moderátor	0,967	0,005	7,9	70 541
SPOLU	0,903	0,008	14,4	39 055
Stačilo!	0,895	0,008	16,5	26 782
SPD	0,889	0,009	17,6	29 300
Motoristé	0,889	0,009	16,1	27 466
STAN	0,887	0,008	17,1	24 875
Přísaha	0,885	0,009	17,0	24 773
ANO	0,883	0,010	14,8	38 639
Piráti	0,869	0,008	20,1	27 308

Z dat vyplývají následující pozorování:

1. **Piráti jako outlier syntaktické komplexity.** Piráti vykazují nejvyšší průměrnou délku věty (20,1 slov) při současně nejnižším TTR mezi politickými stranami (0,869). Tato kombinace naznačuje tendenci k delším, argumentačně strukturovaným souvětím s vyšší mírou lexikální repetice. Jde o diskurzivní styl charakteristický pro expertní, technicistní rétoriku.

2. **ANO a SPOLU: kompaktní vyjadřování.** Obě strany s nejvyšším celkovým počtem slov vykazují nižší průměrnou délku věty (ANO: 14,8; SPOLU: 14,4), přičemž SPOLU dosahuje druhé nejvyšší lexikální diverzity (TTR = 0,903). Tento profil odpovídá komunikačnímu stylu s krátkými, lexikálně variabilními výpověďmi.

3. **SPD: vysoká komplexita i diverzita.** SPD se v bubble chartu nachází ve vyšší části osy y ($\approx$ 17,6 slov/věta) při střední hodnotě TTR, což naznačuje rétoricky expandovaný styl vyjadřování.

4. **Moderátor jako referenční bod.** Moderátor se nachází v pravém dolním rohu grafu — krátké věty (7,9 slov) s extrémně vysokou lexikální diverzitou (TTR = 0,967), což odpovídá funkci kladení krátkých, neopakujících se otázek.

4.3 Heatmapa tematické dominance

Obrázek 3 zobrazuje distribuci pozornosti jednotlivých stran napříč 18 tematickými bloky debat. Hodnoty reprezentují podíl slov strany věnovaných danému tématu (řádková normalizace).

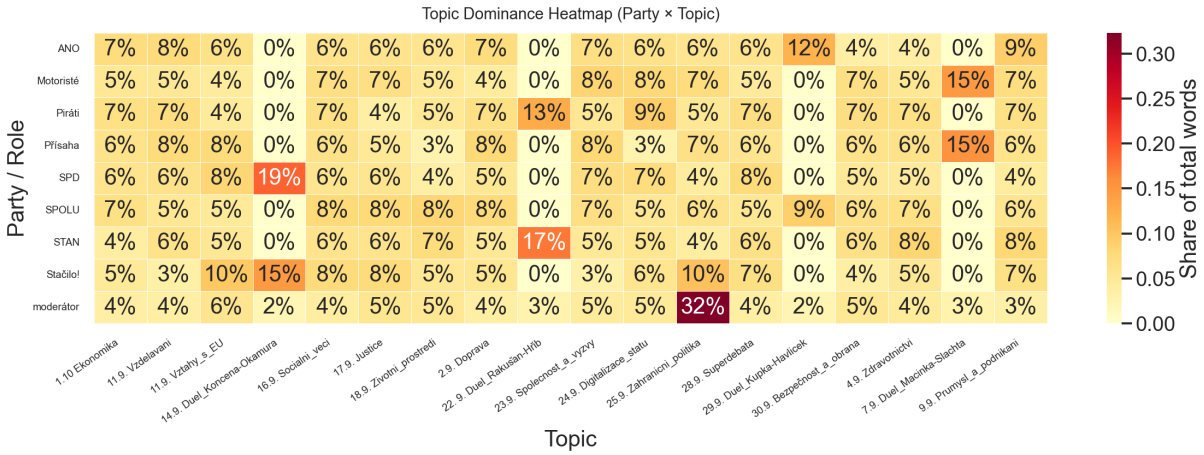

Obrázek 3: Heatmapa tematické dominance (Party × Topic). Hodnoty udávají podíl celkového slovního rozsahu strany věnovaného danému tematickému bloku. Barevná škála YlOrRd — tmavší odstín indikuje vyšší koncentraci.

Klíčová zjištění:

1. **Superdebata jako dominantní blok.** Tematický blok *Superdebata* (28. 9.) koncentruje u většiny stran 10–15 % celkového slovního rozsahu. U strany ANO dosahuje podíl 12 %, u SPD dokonce 15 %, což naznačuje strategické nasazení na tento formát s vysokou sledovaností.

2. **Duelové formáty.** Specifické duely vykazují výrazné koncentrace u příslušných stran — duel *Končená–Okamura* (14. 9.) ukazuje zvýšenou koncentraci u SPD (9 %), duel *Rakušan–Hřib* (22. 9.) dominuje u STAN (17 %). Moderátor vykazuje nejvyšší koncentraci právě v bloku *Superdebata* (32 %), což odpovídá jeho řídící roli v tomto rozsáhlém formátu.

3. **Tematické preference Stačilo!** Strana Stačilo! vykazuje zvýšenou koncentraci v blocích *Sociální věci* (15 %) a *Ekonomika* (10 %), což koresponduje s programovou orientací na sociální a ekonomická témata.

4. **Relativní rovnoměrnost systémových stran.** Velké parlamentní strany (ANO, SPOLU, Piráti) vykazují relativně rovnoměrnou distribuci pozornosti napříč tématy (většina hodnot v rozmezí 4–8 %), což odráží záměr pokrýt celé spektrum politických otázek.

5 Diskuse

Předložené výsledky umožňují formulovat několik obecnějších pozorování o povaze politického diskurzu v české předvolební kampani 2025.

5.1 Sémantická konvergence a diskurzivní mainstream

Dominantní centrální shluk v UMAP projekci (obr. 1) naznačuje, že navzdory deklarovaným ideologickým rozdílům operují české politické strany v ekonomickém tématu ve sdíleném sémantickém prostoru. Toto zjištění je konzistentní s teorií diskurzivního mainstreamu (Angermuller, 2014), podle níž institucionalizovaný politický diskurz tenduje ke konvergenci v základních pojmových rámcích.

Separované okrajové shluky v sémantické mapě představují promluvy, které se sémanticky vymykají hlavnímu proudu — mohou jít o procedurální výroky, emotivní prohlášení nebo stylisticky odlišné duelové formáty. Jejich přítomnost napříč stranami potvrzuje, že sémantická odlišnost je dána spíše komunikačním žánrem než stranickou příslušností.

5.2 Lexikální profily jako indikátory rétorického stylu

Kombinace TTR a průměrné délky věty vytváří dvoudimenzionální prostor rétorických stylů (obr. 2). Pozice Pirátů — s nejdelšími větami a nejnižší lexikální diverzitou — indikuje diskurzivní strategii založenou na komplexní argumentaci s opakovaným používáním klíčových termínů. Naopak pozice SPOLU — krátké věty, vysoká diverzita — naznačuje komunikační styl orientovaný na heslovitost a lexikální variabilitu.

Je třeba poznamenat, že TTR je citlivé na délku textu — delší promluvy přirozeně vykazují nižší TTR. Maas index tuto závislost logaritmickou transformací tlumí, přičemž pořadí stran zůstává v obou metrikách konzistentní, což posiluje robustnost zjištění.

5.3 Tematické strategie a formátové efekty

Heatmapa tematické dominance (obr. 3) odhaluje interakci mezi stranickými preferencemi a formátem debaty. Duelové formáty přirozeně koncentrují slovní rozsah u příslušných stran, zatímco Superdebata funguje jako tematicky nejrovnoměrnější platforma. Zvýšená koncentrace menších a protisystémových stran na specifická témata může odrážet jak programovou specializaci, tak strategické rozhodnutí soustředit omezený diskurzivní prostor na vybraná témata.

5.4 Limity studie

Předložená analýza má několik omezení, která je třeba reflektovat:

- **Tokenizace.** Použitá jazykově agnostická tokenizace (segmentace na mezerách) nerespektuje morfologickou strukturu češtiny. Lemmatizace nebo morfologická analýza by mohla poskytnout přesnější hodnoty lexikálních metrik.

- **Závislost TTR na délce.** Přestože Maas index tuto závislost zmírňuje, komparace stran s výrazně odlišným počtem promluv (Piráti: 401 vs. SPOLU: 840) vyžaduje interpretační obezřetnost.
- **Determinismus LLM anotací.** Anotace sentimentu, agresivity a rétorických rámců generované velkým jazykovým modelem jsou inherentně nedeterministické. Pro plnou reprodukovatelnost je nezbytné verzovat výstupní datový soubor.
- **Jednorozměrnost embeddingového modelu.** Použitý model `paraphrase-multilingual-MiniLM-L12-v2` optimalizuje sémantickou podobnost na úrovni parafrází; pragmatické, ironické a konativní dimenze diskurzu mohou být v embeddingu nedostatečně zachyceny.

6 Závěr

Předkládaná studie demonstrovala, že kvantitativní metody založené na sentence embeddingách, redukci dimenzí a lexikálních metrikách mohou poskytnout systematický a reprodukovatelný pohled na strukturu politického diskurzu. Pipeline PDT transformuje surový textový přepis na trojici vizualizací — sémantickou mapu, bubble chart rétorického profilu a heatmapu tematické dominance — které společně zachycují sémantické, lexikální a tematické dimenze diskurzivního prostoru.

Pro obecnou lingvistiku má navržený přístup dvojí přínos. Za prvé, demonstroval aplikovatelnost multilinguálních sentence embeddingů na český politický diskurz — materiál se specifickou slovní zásobou, syntaktickou strukturou a pragmatickými konvencemi. Za druhé, ukázal, že kombinace kvantitativních metrik (TTR, Maas, UMAP) s kvalitativní interpretací grafů může generovat lingvisticky relevantní hypotézy o diskurzivních strategiích bez nutnosti a priori stanovovat analytické kategorie.

Budoucí výzkum by mohl rozšířit analýzu o temporální dimenzi (vývoj sémantického prostoru v čase debaty), interakční analýzu (komu kdo odpovídá) a kontrastivní srovnání s korpusy politických debat v jiných jazycích středoevropského prostoru.

Dostupnost dat a kódu

Veškerý zdrojový kód analytické pipeline, vstupní data i výstupní vizualizace jsou veřejně dostupné v repozitáři:

https://github.com/Dobes-Michal-Tobias/Semantic-debate-mapping

Repozitář obsahuje soubor `requirements.txt` s výčtem závislostí a instrukce pro reprodukci všech fází analýzy.

Literatura

1. Angermuller, J. (2014). *Poststructuralist Discourse Analysis: Subjectivity in Enunciative Pragmatics.* Palgrave Macmillan.

2. Fairclough, N. (1995). *Critical Discourse Analysis: The Critical Study of Language.* Longman.

3. Maas, H. D. (1972). Über den Zusammenhang zwischen Wortschatzumfang und Länge eines Textes. *Zeitschrift für Literaturwissenschaft und Linguistik,* 2(8), 73–79.

4. McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv preprint arXiv:1802.03426.*

5. Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP),* 3982–3992.

6. van Dijk, T. A. (2001). Multidisciplinary CDA: A Plea for Diversity. In R. Wodak & M. Meyer (Eds.), *Methods of Critical Discourse Analysis* (pp. 95–120). SAGE.