

Mapování sémantické konvergence a lexikální diverzity v předvolebních debatách 2025*

Michal Tobiáš Dobeš

Katedra obecné lingvistiky, Univerzita Palackého v Olomouci

Předmět: **KRAD** — Kritická analýza diskurzu

Březen 2026

Abstrakt

Předkládaná studie navrhuje a aplikuje kvantitativní pipeline pro analýzu politického diskurzu na korpusu 7715 promluv z předvolebních debat České televize (podzim 2025). Metodologický rámec propojuje sentence embeddingy (model `paraphrase-multilingual-MiniLM-L12-v2`), redukci dimenzí algoritmem UMAP, lexikální metriky (Type-Token Ratio, Maas index) s pokročilou strojovou klasifikací promluv pomocí velkých jazykových modelů, umožňující detekci sentimentu, míry agresivity či dominantních rétorických rámců. Výsledky vizualizované prostřednictvím sémantické mapy, bubble chartu rétorického profilu a heatmapy tematické dominance ukazují výraznou konvergenci středových stran v sémantickém prostoru, odlišnou syntaktickou komplexitu Pirátů a specifické tematické strategie protisystémových subjektů. Navržená metoda demonstruje potenciál počítačnických přístupů pro obecnou lingvistiku a kritickou analýzu diskurzu.

Klíčová slova: politický diskurz, sentence embeddings, UMAP, lexikální diverzita, Maas index, kvantitativní lingvistika, NLP, předvolební debaty

*Zdrojový kód a data: <https://github.com/Dobes-Michal-Tobias/Semantic-debate-mapping>

Obsah

1	Úvod	3
2	Data	3
3	Metodologie	4
3.1	Fáze 1: Parsování přepisu	4
3.2	Fáze 2: Lexikální metriky	4
3.3	Fáze 3: Sentence embeddingy	5
3.4	Fáze 4: Redukce dimenzí	5
3.5	Fáze 5: LLM anotace	6
3.6	Fáze 6: Vizualizace	6
4	Výsledky	6
4.1	Sémantická mapa politického diskurzu	6
4.2	Rétorický profil: Lexikální diverzita a syntaktická komplexita	8
4.3	Heatmapa tematické dominance	9
5	Diskuse	11
5.1	Sémantická konvergence a diskurzivní mainstream	11
5.2	Lexikální profily jako indikátory rétorického stylu	11
5.3	Tematické strategie a formátové efekty	12
5.4	Limity studie	12
6	Závěr	12
	Dostupnost dat a kódu	13
	Literatura	13

1 Úvod

Předvolební kampaň před volbami do Poslanecké sněmovny ČR v říjnu 2025 představovala v českém politickém prostředí událost s vysokou diskurzivní dynamikou. Televizní debaty České televize, vysílané od září do října 2025, poskytly systematický a veřejně přístupný zdroj politických promluv pokrývajících široké spektrum témat — od ekonomiky přes vzdělávání po zahraniční politiku. Tento materiál tak vytváří vhodný korpus pro kvantitativní analýzu politického diskurzu.

Kritická analýza diskurzu (CDA), jak ji rozpracovali Fairclough (1995) a van Dijk (2001), byla tradičně kvalitativní disciplínou, založenou na interpretativní práci výzkumníka s textem. S rozvojem metod zpracování přirozeného jazyka (NLP) a zejména s příchodem kontextuálních jazykových modelů se však otevírá prostor pro komplementární kvantitativní přístupy, které umožňují zpracovat rozsáhlé korpusy a identifikovat vzorce nepozorovatelné manuální analýzou.

Předkládaná studie si klade za cíl navrhnout a aplikovat reprodukovatelnou analytickou pipeline, která transformuje surové textové přepisy debat na strukturované sémantické, lexikální a rétorické reprezentace. Konkrétně jsou formulovány tři výzkumné otázky:

1. Jak se liší sémantický prostor projevů jednotlivých politických stran, měřeno prostřednictvím shluků ve dvourozměrné UMAP projekci sentence embeddingů?
2. Jaká je lexikální rozmanitost a syntaktická komplexita vyjadřování napříč stranami, kvantifikovaná pomocí TTR a Maas indexu?
3. Jaké tematické a rétorické strategie strany využívají v kontextu předvolební debaty?

2 Data

Analýzovaný korpus tvoří přepisy debat České televize z předvolebního období (září–říjen 2025). Základní parametry datového souboru shrnuje tabulka 1.

Tabulka 1: Přehled analyzovaného korpusu

Parametr	Hodnota
Počet promluv (speech acts)	7 715
Počet politických subjektů	8 stran + moderátor
Počet unikátních mluvčích	115
Počet tematických bloků	18
Kódování zdrojového souboru	UTF-8

V korpusu je zastoupeno osm politických subjektů: ANO, SPOLU, Piráti, STAN, SPD, Stačilo!, Motoristé sobě a Přísaha. Tematické bloky pokrývají oblast ekonomiky, dopravy, zdravotnictví, průmyslu, vzdělávání, vztahů s EU, justice, životního prostředí, společenských výzev, digitalizace, zahraniční politiky, bezpečnosti a obrany, jakož i několik přímých duelů mezi kandidáty. Promluvy moderátorů (celkem 3 155) jsou v analýze zachovány jako referenční kategorie, neboť jejich diskurzivní profil (krátké, lexikálně diverzní výroky) poskytuje zajímavý kontrast.

Tabulka 2: Počet promluv a celkový rozsah projevů dle politického subjektu

Strana / Role	Počet promluv	Celkem slov	Počet mluvčích
moderátor	3 155	70 541	14
SPOLU	840	39 055	13
ANO	721	38 639	12
SPD	579	29 300	13
Motoristé	546	27 466	12
Stačilo!	534	26 782	13
Přísaha	491	24 773	12
STAN	448	24 875	13
Piráti	401	27 308	13

3 Metodologie

Analytická pipeline sestává z šesti fází, z nichž pátá (LLM obohacení) je volitelná. Každá fáze implementuje princip idempotence — kontroluje existenci výstupního souboru a shodu počtu řádků, čímž je zajištěna reprodukovatelnost i efektivita opakovaných běhů.

3.1 Fáze 1: Parsování přepisu

Surový textový přepis je transformován na strukturovaný tabulkový formát (CSV) pomocí regulárního výrazu, který rozpoznává hlavičku promluvy ve formátu:

Jméno Příjmení (Strana) [HH:MM:SS] (Téma): Text promluvy

Pokračovací řádky (bez hlavičky) jsou připojeny k předchozí promluvě. Pro každou promluvu jsou vypočteny odvozené atributy: časová značka v sekundách, počet slov, počet vět (detekce koncových interpunkčních znaků) a průměrná délka věty ve slovech.

3.2 Fáze 2: Lexikální metriky

Pro kvantifikaci lexikální diverzity jsou použity dvě komplementární míry:

Type-Token Ratio (TTR). Poměr počtu unikátních slovních typů V k celkovému počtu tokenů N :

$$\text{TTR} = \frac{|V|}{|N|} \quad (1)$$

Hodnota blízká 1,0 indikuje vysokou lexikální variabilitu; hodnota blízká 0 naopak signalizuje vysokou míru opakování.

Maas index (Maas, 1972). Logaritmická transformace, která tlumí závislost na délce textu:

$$a^2 = \frac{\log N - \log V}{(\log N)^2} \quad (2)$$

Nižší hodnota a^2 indikuje vyšší lexikální bohatství. Tato míra je vhodnější pro komparativní analýzu promluv různých délek než prostý TTR.

Tokenizace je implementována jazykově nezávislým způsobem bez ohledu na gramatická či morfologická specifika daného jazyka (převod na malá písmena, segmentace na mezerách).

3.3 Fáze 3: Sentence embeddingy

Každá promluva je zakódována do hustého vektorového prostoru pomocí modelu `paraphrase-multilingual-MiniLM-L12-v2` z knihovny Sentence Transformers (Reimers a Gurevych, 2019). Jedná se o dvanáctivrstvý multilinguální model založený na architektuře MiniLM, trénovaný na parafrázových párech ve více než 50 jazycích včetně češtiny. Výstupní dimenze embeddingu je 384.

Model produkuje pro každou promluvu vektor $\mathbf{e}_i \in \mathbb{R}^{384}$, kde sémanticky podobné promluvy mají vysokou kosinovou podobnost. Celkem bylo zakódováno 7 715 promluv s velikostí dávky 64.

3.4 Fáze 4: Redukce dimenzí

Pro vizualizaci 384-dimenzionálního embeddingového prostoru ve dvou dimenzích byl použit algoritmus UMAP (Uniform Manifold Approximation and Projection; McInnes et al., 2018). UMAP zachovává jak lokální, tak globální topologickou strukturu dat, čímž poskytuje věrohodnější vizuální reprezentaci sémantických shluků než lineární metoda PCA. Parametry redukce: `n_components=2`, `random_state=42`.

Jako záložní metoda je implementována PCA z knihovny `scikit-learn`, která se automaticky aktivuje v prostředí bez nainstalovaného balíčku `umap-learn`.

Pro každou politickou stranu je dále vypočten **centroid** — průměrný embeddingový vektor všech promluv dané strany v plném 384D prostoru. Mezistraná kosinová vzdálenost centroidů slouží jako míra celkové sémantické odlišnosti rétorických pozic.

3.5 Fáze 5: LLM anotace

Promluvy mohou být volitelně obohaceny o automaticky generované anotace pomocí modelu Claude (Anthropic API). Pro každou promluvu jsou generovány tři tagy: *sentiment* (plovoucí hodnota na škále $-1,0$ až $1,0$), *agresivita* (celočíslná škála 0–5) a *dominantní rétorický rámec* (kategoriální proměnná: Economic threat, National sovereignty, Social justice, Fiscal responsibility, EU scepticism, Party attack, Neutral/factual).

Zpracování probíhá v dávkách po 20 promluvách s automatickým checkpointingem po každé dávce, čímž je umožněno přerušení a obnovení procesu.


3.6 Fáze 6: Vizualizace

Na základě vypočtených metrik a embeddingů jsou generovány tři vizualizace: sémantická mapa (scatter plot UMAP projekce), bubble chart rétorického profilu a heatmapa tematické dominance. Technické parametry vizualizací jsou popsány v sekci 4.

4 Výsledky

4.1 Sémantická mapa politického diskurzu

Obrázek 1 zobrazuje dvourozměrnou UMAP projekci sentence embeddingů všech 7715 promluv. Každý bod představuje jednu promluvu, barva kóduje stranickou příslušnost; hvězdičky označují 2D centroidy stran.




Obrázek 1: Sémantická mapa promluv (UMAP projekce). Každý bod odpovídá jedné promluvě, barva indikuje stranickou příslušnost. Hvězdičky označují centroidy stran v 2D prostoru.

Z vizualizace lze identifikovat několik klíčových vzorců:

1. **Centrální sémantický shluk.** Většina promluv všech parlamentních stran se koncentruje v jednom dominantním shluku v levé části projekce (přibližně $\text{dim}_0 \in [-5, 5]$, $\text{dim}_1 \in [0, 8]$). Tato konvergence naznačuje, že politický diskurz témat sdílí značnou část sémantického prostoru napříč ideologickým spektrem.
2. **Sémantická pozice moderátora.** Promluvy moderátora vykazují výraznou tendenci ke shlukování v rámci hlavního sémantického clusteru, což reflektuje jeho věcně neutrální a organizační roli. Přesto je u těchto promluv patrná tendence k formování vlastních specifických podshluků; tato diskurzivní distinkce pravděpodobně odráží funkční odlišnost metajazykových a procedurálních prvků od věcné argumentace politických aktérů.
3. **Okrajové shluky.** V horní části projekce i na pravo od hlavního dominantního clusteru lze pozorovat separované menší shluky ($\text{dim}_0 > 10$), které představují sémanticky odlišné typy promluv — pravděpodobně procedurální výroky, emotivní prohlášení nebo specifické duelové formáty. Tyto okrajové body jsou zastoupeny napříč stranami.

4.2 Rétorický profil: Lexikální diverzita a syntaktická komplexita

Obrázek 2 zobrazuje bubble chart, kde osa x reprezentuje průměrnou lexikální diverzitu (TTR), osa y průměrnou délku věty ve slovech a velikost bubliny odpovídá míře agresivity (pokud jsou dostupné LLM tagy).



Obrázek 2: Rétorický profil stran: lexikální diverzita (TTR) na ose x , průměrná délka věty na ose y . Velikost bubliny odpovídá míře agresivity.

Kvantitativní hodnoty lexikálních metrik shrnuje tabulka 3.

Tabulka 3: Lexikální metriky dle politického subjektu (seřazeno dle TTR)


Strana / Role	$\overline{\text{TTR}}$	$\overline{a^2}$ (Maas)	$\bar{\ell}$ (slov/věta)	Celkem slov
moderátor	0,967	0,005	7,9	70 541
SPOLU	0,903	0,008	14,4	39 055
Stačilo!	0,895	0,008	16,5	26 782
SPD	0,889	0,009	17,6	29 300
Motoristé	0,889	0,009	16,1	27 466
STAN	0,887	0,008	17,1	24 875
Přísaha	0,885	0,009	17,0	24 773
ANO	0,883	0,010	14,8	38 639
Piráti	0,869	0,008	20,1	27 308

Z dat vyplývají následující pozorování:

1. **Piráti jako outlier syntaktické complexity.** Piráti vykazují nejvyšší průměrnou délku věty (20,1 slov) při současně nejnižším TTR mezi politickými stranami (0,869). Tato kombinace naznačuje tendenci k delším, argumentačně strukturovaným souvětím s vyšší mírou lexikální repetice. Může jít o styl charakteristický pro expertní, technicistní rétoriku.
2. **ANO a SPOLU: kompaktní vyjadřování.** Obě strany s nejvyšším celkovým počtem slov vykazují nižší průměrnou délku věty (ANO: 14,8; SPOLU: 14,4), přičemž SPOLU dosahuje druhé nejvyšší lexikální diverzity ($\text{TTR} = 0,903$). Tento profil odpovídá komunikačnímu stylu s krátkými, lexikálně variabilními výpověďmi.
3. **SPD: vysoká komplexita i diverzita.** SPD se v bubble chartu nachází ve vyšší části osy y ($\approx 17,6$ slov/věta) při střední hodnotě TTR, což naznačuje rétoricky expandovaný styl vyjadřování.
4. **Moderátor jako referenční bod.** Moderátor se nachází v pravém dolním rohu grafu — krátké věty (7,9 slov) s extrémně vysokou lexikální diverzitou ($\text{TTR} = 0,967$), což odpovídá funkci kladení krátkých, neopakujících se otázek.

4.3 Heatmapa tematické dominance

Obrázek 3 zobrazuje distribuci pozornosti jednotlivých stran napříč 18 tematickými bloky debat. Hodnoty reprezentují podíl slov strany věnovaných danému tématu (řádková normalizace).



Obrázek 3: Heatmapa tematické dominance (Party × Topic). Hodnoty udávají podíl celkového slovního rozsahu strany věnovaného danému tematickému bloku. Barevná škála YlOrRd — tmavší odstín indikuje vyšší koncentraci.

Klíčová zjištění:

- **Dominance moderátora v zahraniční politice.** Výrazným rysem heatmapy je anomální koncentrace promluv moderátora v bloku „Zahraniční politika“ (32 %), což ostře kontrastuje s jeho minimálním zapojením v duelových formátech (2–3 %). Tato hodnota může indikovat buď rozsáhlé moderátorské expozice v daném tématu, nebo potenciální nesrovnalost v datovém souboru.
- **Strategická stabilita hnutí ANO.** Projevy hnutí ANO vykazují vysokou míru tematické stability v rozmezí 6–8 % u většiny agend. Signifikantní propad je však patrný v tématech bezpečnosti a obrany (4 %) a zdravotnictví (4 %).
- **Tematické priority Motoristů.** Subjekt vykazuje cílené zaměření na oblasti „Společnost a výzvy“ a „Digitalizace státu“, kde dosahuje shodně 8 % svého celkového slovního rozsahu, což je mírně nadprůměrná hodnota ve srovnání s jejich ostatními agendami.
- **Digitalizační akcent Pirátů.** Agenda Pirátů je rozdělena do dvou úrovní: primární skupina témat vykazuje podíl kolem 7 %, zatímco sekundární agendy (např. justice, vztahy s EU) se pohybují kolem 4–5 %. Výjimku tvoří téma „Digitalizace státu“ (9 %), do kterého se Piráti zapojili výrazněji než do většiny ostatních bloků, což patrně souvisí s akcentem na agendu ex-ministra Bartoše.
- **Konfrontační dominance SPD.** Strategie SPD je charakteristická extrémním výkyvem v rámci duelového formátu (14. 9.), kde předseda Okamura generuje 19 % celkového slovního objemu strany, což výrazně převyšuje podíl v jakémkoliv jiném tematickém bloku.

- **Programová vyváženost koalice SPOLU.** Jako klíčový subjekt tehdejší vládní koalice vykazuje SPOLU nejrovnoměrnější distribuci promluv napříč všemi bloky (většinou 7–8 %). Tato rovnoměrnost indikuje snahu o komplexní pokrytí celého vládního spektra bez výrazných prioritních či deficitních témat.
- **Vysoká agendační volatilita Stačilo!.** Projevy subjektu Stačilo! vykazují značnou nevyrovnanost; výrazně se soustředí na témata „Vztahy s EU“ a „Zahraniční politika“ (shodně 10 %), avšak téměř zcela opomíjejí oblasti bezpečnosti (4 %), vzdělávání (3 %) či společenských výzev (3 %).

5 Diskuse

Předložené výsledky umožňují formulovat několik obecnějších pozorování o povaze politického diskurzu v české předvolební kampani 2025.

5.1 Sémantická konvergence a diskurzivní mainstream

Dominantní centrální shluk v UMAP projekci (obr. 1) naznačuje, že navzdory deklarovaným ideologickým rozdílům operují české politické strany v předvolebních tématech ve sdíleném sémantickém prostoru. Toto zjištění je konzistentní s teorií diskurzivního mainstreamu (Angermüller, 2014), podle níž institucionalizovaný politický diskurz tenduje ke konvergenci v základních pojmových rámcích.

Separované okrajové shluky v sémantické mapě představují promluvy, které se sémanticky vymykají hlavnímu proudu — mohou jít o procedurální výroky, emotivní prohlášení nebo stylisticky odlišné duelové formáty. Jejich přítomnost napříč stranami potvrzuje, že sémantická odlišnost je dána spíše komunikačním žánrem než stranickou příslušností.

5.2 Lexikální profily jako indikátory rétorického stylu

Kombinace TTR a průměrné délky věty vytváří dvoudimenzionální prostor rétorických stylů (obr. 2). Pozice Pirátů — s nejdelšími větami a nejnižší lexikální diverzitou — indikuje diskurzivní strategii založenou na komplexní argumentaci s opakovaným používáním klíčových termínů. Naopak pozice SPOLU — krátké věty, vysoká diverzita — naznačuje komunikační styl orientovaný na heslovitost a lexikální variabilitu.

Je třeba poznamenat, že TTR je citlivé na délku textu — delší promluvy přirozeně vykazují nižší TTR. Maas index tuto závislost logaritmickou transformací tlumí, přičemž pořadí stran zůstává v obou metrikách konzistentní, což posiluje robustnost zjištění.

5.3 Tematické strategie a formátové efekty

Heatmapa tematické dominance (obr. 3) odhaluje interakci mezi stranickými preferencemi a formátem debaty. Duelové formáty přirozeně koncentrují slovní rozsah u příslušných stran, zatímco Superdebata funguje jako tematicky nejrovnoměrnější platforma. Zvýšená koncentrace menších a protisystémových stran na specifická témata může odrážet jak programovou specializaci, tak strategické rozhodnutí soustředit omezený diskurzivní prostor na vybraná témata.

5.4 Limity studie

Předložená analýza má několik omezení, která je třeba reflektovat:

- **Tokenizace.** Použitá jazykově agnostická tokenizace (segmentace na mezerách) nerespektuje morfologickou strukturu češtiny. Lemmatizace nebo morfologická analýza by mohla poskytnout přesnější hodnoty lexikálních metrik.
- **Závislost TTR na délce.** Přestože Maas index tuto závislost zmírňuje, komparace stran s výrazně odlišným počtem promluv (Piráti: 401 vs. SPOLU: 840) vyžaduje interpretační obezřetnost.
- **Determinismus LLM anotací.** Anotace sentimentu, agresivity a rétorických rámců generované velkým jazykovým modelem jsou inherentně nedeterministické. Pro plnou reprodukovatelnost je nezbytné verzovat výstupní datový soubor.
- **Jednorozměrnost embeddingového modelu.** Použitý model `paraphrase-multilingual-MiniLM-L12-v2` optimalizuje sémantickou podobnost na úrovni parafrází; pragmatické, ironické a konativní dimenze diskurzu mohou být v embeddingu nedostatečně zachyceny.

6 Závěr

Předkládaná studie demonstrovala, že kvantitativní metody založené na sentence embeddingách, redukci dimenzí a lexikálních metrikách mohou poskytnout systematický a reprodukovatelný pohled na strukturu politického diskurzu. Pipeline transformuje surový textový přepis na trojici vizualizací — sémantickou mapu, bubble chart rétorického profilu a heatmapu tematické dominance — které společně zachycují sémantické, lexikální a tematické dimenze diskurzivního prostoru.

Pro obecnou lingvistiku má navržený přístup dvojí přínos. Za prvé, demonstroval aplikovatelnost multilinguálních sentence embeddingů na český politický diskurz — materiál se specifickou slovní zásobou, syntaktickou strukturou a pragmatickými konvencemi. Za druhé, ukázal, že kombinace kvantitativních metrik (TTR, Maas, UMAP) s kvalitativní

interpretací grafů může generovat lingvisticky relevantní hypotézy o diskurzivních strategiích bez nutnosti a priori stanovovat analytické kategorie.

Budoucí výzkum by mohl rozšířit analýzu o temporální dimenzi (vývoj sémantického prostoru v čase debaty), interakční analýzu (komu kdo odpovídá) a srovnání s korpusy politických debat v jiných jazycích středoevropského prostoru.

Dostupnost dat a kódu

Veškerý zdrojový kód analytické pipeline, vstupní data i výstupní vizualizace jsou veřejně dostupné v repozitáři:

<https://github.com/Dobes-Michal-Tobias/Semantic-debate-mapping>

Repozitář obsahuje soubor `requirements.txt` s výčtem závislostí a instrukce pro reprodukci všech fází analýzy.

Literatura

1. Angermuller, J. (2014). *Poststructuralist Discourse Analysis: Subjectivity in Enunciative Pragmatics*. Palgrave Macmillan.
2. Fairclough, N. (1995). *Critical Discourse Analysis: The Critical Study of Language*. Longman.
3. Maas, H. D. (1972). Über den Zusammenhang zwischen Wortschatzumfang und Länge eines Textes. *Zeitschrift für Literaturwissenschaft und Linguistik*, 2(8), 73–79.
4. McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv preprint arXiv:1802.03426*.
5. Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 3982–3992.
6. van Dijk, T. A. (2001). Multidisciplinary CDA: A Plea for Diversity. In R. Wodak & M. Meyer (Eds.), *Methods of Critical Discourse Analysis* (pp. 95–120). SAGE.